大数据技术与应用(二)课程设计

3	:	大数据技术与应用(二)课程设计
]	:	基于 Spark 的出租房屋大数据分析
及	:	
ュ	:	
Ż	:	
)	国 及 哥	

目录

1.	项目	背景与功能	. 1
	1.1	项目背景	. 1
	1.2	项目功能	. 1
	1.3	运行环境	. 1
2.	数据组	集与数据预处理	. 1
	2.1	原始数据集	. 1
		2.1.1 数据集说明	. 1
		2.1.2 原始数据集展示 (前 10 条)	.2
	2.2	数据预处理	.3
		2.2.1 Excel 数据预处理	.3
		2.2.2 数据字段说明	.3
	2.3	数据上传	.3
		2.3.1 处理数据	.3
		2.3.2 上传至 HDFS	.4
3.	数据	分析	.5
	3.1	使用 Spark SQL 进行统计分析 (至少 5 个)	.5
		3.1.1 统计租金前 10 的市辖区	
		3.1.2 统计市辖区出租房屋的最大面积和最小面积	.5
		3.1.3 统计市辖区出租房屋的平均面积及平均租金	
		3.1.4 统计地级市租金在 1000 以上的房屋数量	.7
		3.1.5 统计地级市一房一厅一卫的房屋最低租金	.7
4.	Flask	与 ECharts 数据大屏可视化	.7
	4.1	开发环境及伪动态算法介绍	
		4.1.1 利用 Flask 与 ECharts	.8
		4.1.2 伪动态算法建模	
	4.2	Flask+ ECharts 可视化	.9
		4.2.1 数据导入 mysql	
		4.2.2 总体情况预览可视化分析	.9
		4.2.3 深圳、佛山租房各项指标对比	
		4.2.4 不同朝向的租房房间数量、楼层可视化分析	
		4.2.5 地区均价与面积对比分析	
		4.2.6 房源数量 TOP10 分析	
		4.2.7 租房类型对比	
		4.2.8 租房覆盖率分析展示	
		总体大屏可视化结果展示	
5.	1	机器学习	
	5.1	K-Means 聚类分析	16
		5.1.1 数据预处理	
		5.1.2 特征工程	
		5.1.3 K-Means 模型聚类	
		5.1.4 模型评估	
		5.1.5 模型优化	19

. 19 . 19 . 20 . 20
. 19 . 20 . 20
.20 .20
.20
.20
.21
.22
.22
.22
.23
.24
.26
.27

1. 项目背景与功能

1.1 项目背景

此次项目是分析广东七地二手房的房子情况,数据是来自链家的二手房,此次的爬取的数据是 2023 年 5 月最新的数据,数据包含了十个字段,都是爬取后在 excel 做了简单的数据预处理,最后导入虚拟机。

1.2 项目功能

本项目通过 EXCEL 对出租房屋数据集进行预处理,并使用 Spark SQL 进行了租金前十的市辖区、各市辖区出租房屋的最大面积、最小面积、平均面积等数据分析;使用 Flask+Echarts 对数据进行大屏可视化;使用 K-Means 聚类对出租房屋进行聚类分析,根据聚类结果可知,该数据集可分为三类;使用 Lasson 回归模型进行预测租金,该模型优化后 RMSE 值为 1074;

1.3 运行环境

使用 Ubuntu16.04 的虚拟机版本,软件方面使用的有 Hadoop2.7.1、Spark2.1.0、HBase1.1.5、JDK1.8、Scala2.11.8、MySQL、Kafka_2.11-0.10.2.0、Sbt、Maven3.3.9、Hive2.1.0、Pycharm2016.3、python3.8

2. 数据集与数据预处理

2.1 原始数据集

2.1.1 数据集说明

清远租房信息_清远出租房源 房屋出租价格【 我的任务组 9 天前	口 启动 未运行 口 启动 已停止 采集到3000条数据(重	未设置	- 9分31秒
湛江租房信息_湛江出租房源 房屋出租价格【 我的任务组 9 天前	□ 启动 未运行 全部 □ 启动 □ 已停止 采集到2400条数据(重 全部	未设置	- 9分40利
惠州租房信息,惠州出租房源1房屋出租价格【 我的任务组 9 天前	□ 启动 未运行 □ 启动 已停止 采集到3000条数据(重	未设置	- 10分3利
珠海租房信息_珠海出租房源 房屋出租价格【 我的任务组 9 天前	□ 启动 未运行 □ 启动 已停止 采集到1700条数据(重	未设置	- 6分9秒
深圳租房信息_深圳出租房源房屋出租价格【 我的任务组 9 天前	□ 启动 未运行 □ 启动 已停止 采集到1700条数据(重	未设置	- 47分17
中山租房信息_中山出租房源1房屋出租价格【 我的任务组 9 天前	□ 启动 未运行 □ 启动 已停止 采集到1900条数据(重	未设置	- 8分4秒
佛山租房信息_佛山出租房源房屋出租价格【 我的任务组 9天前	□ 启动 未运行 □ 启动 已停止 采集到1700条数据(重	未设置	- 7分8秒

图 2-1 数据集采集

采集时间: 2023-5-8

采集网址: https://fs.lianjia.com/zufang/、 https://sz.lianjia.com/zufang/、 https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/、https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/。https://sz.lianjia.com/zufang/

https://qy.lianjia.com/zufang/

内容: 佛山、深圳、珠江、湛江、惠州、清远、中山七个城市的租房信息

2.1.2 原始数据集展示 (前 10 条)

	A	В	С	D	Е	F	G H
1	珠海	香洲区-吉 大-德丰大 厦	80.00m²	东南	3室1厅1卫	中 楼 层 (11层)	1000 元/月
2	珠海	香洲区-吉 大-海湾花 园	134.00㎡	东南	3室1厅2卫	低 楼 层 (29层)	16000 元/月
3	珠海	香洲区-吉 大-嘉年华 国际公寓	48.40m²	东	1室1厅1卫	低 楼 层 (29层)	2300 元/月
4	珠海	香洲区-吉 大-雍和花 园	267.00㎡	东南	5室2厅2卫	高 楼 层 (22层)	3500 元/月
5	珠海	香洲区-吉 大-园林花 园二期	89.00m²	东南	2室2厅1卫	中 楼 层 (17层)	3300 元/月
6	珠海	香洲区-翠 微-东方新 地	111.68㎡	东南	3室2厅2卫	高楼层(7 层)	2700 元/月
7	珠海	香洲区-前山-荣泰河 庭	79.00m²	西南	2室2厅1卫	低 楼 层 (11层)	2500 元/月
8	珠海	香洲区-老香洲-中珠 水晶堡	120.00㎡	南北	4室1厅0卫	低 楼 层 (20层)	2000 元/月
9	珠海	香洲区-老香洲-华富街	121.00㎡	南	3室2厅2卫	高楼层(8 层)	2200 元/月
10	珠海	香洲区-老香洲-梅华东路284号	74.00㎡	南	2室1厅1卫	高楼层(5 层)	2700 元/月
4	→ S	Sheet1	+				
就绪	分辅助 项	助能: 一切就绪					

图 2-2 原始数据集

2.2 数据预处理

2.2.1 Excel 数据预处理

	Α	В	С	D	Е	F	G	Н	1
1	district	address	area(m²)	orientatio	room	living	bathroom	floor	rent
2	珠海	香洲区	397	南	9	4	8	4	100000
3	珠海	香洲区	556	东南	5	2	0	36	55600
4	珠海	香洲区	316	东南	4	2	4	42	40000
5	珠海	香洲区	255	南北	4	2	3	17	30000
6	珠海	香洲区	379.24	东南	6	2	3	24	29000
7	珠海	香洲区	395	西	5	3	4	3	26000
8	珠海	香洲区	299.43	东南	5	2	4	23	22000
9	珠海	香洲区	211	东南	4	2	3	44	20000
10	珠海	香洲区	260	东	1	0	0	33	20000

图 2-3 数据集预处理

2.2.2 数据字段说明

列名称	说明
district	字符串类型,所在地级市
address	字符串类型,所在市辖区
area	浮点数类型,出租房屋面积
orientation	字符串类型,出租房屋朝向
room	整数类型,室数
living	整数类型,厅数
bathroom	整数类型,卫生间数
floor	整数类型,所在楼层
rent	整数类型,租金

2.3 数据上传

2.3.1 处理数据

3940 NodeManager

3455 DataNode

4246 Jps 3657 SecondaryNameNode

```
hadoop@dblab-VirtualBox:~$ cd /usr/local/hadoop
hadoop@dblab-VirtualBox:/usr/local/hadoop$ ./sbin/start-all.sh
This script is Deprecated. Instead use start-dfs.sh and start-yarn.sh
Starting namenodes on [localhost]
localhost: starting namenode, logging to /usr/local/hadoop/logs/hadoop-hadoop-na
menode-dblab-VirtualBox.out
localhost: starting datanode, logging to /usr/local/hadoop/logs/hadoop-hadoop-da
tanode-dblab-VirtualBox.out
Starting secondary namenodes [0.0.0.0]
0.0.0.0: starting secondarynamenode, logging to /usr/local/hadoop/logs/hadoop-hadoop-secondarynamenode-dblab-VirtualBox.out
starting yarn daemons
starting resourcemanager, logging to /usr/local/hadoop/logs/yarn-hadoop-resource
manager-dblab-VirtualBox.out
localhost: starting nodemanager, logging to /usr/local/hadoop/logs/yarn-hadoop-n
odemanager-dblab-VirtualBox.out
hadoop@dblab-VirtualBox:/usr/local/hadoop$ jps
3299 NameNode
3811 ResourceManager
```

图 2-4 启动 Hadoop

```
hadoop@dblab-VirtualBox:~$ cd /usr/local/bigdata/dataset
 hadoop@dblab-VirtualBox:/usr/local/bigdata/dataset$ head -10 rent.csv
hadoop@dblab-VirtualBox:/usr/local/bigd
珠海,香洲区,397,南,9,4,8,4,100000,
珠海,香洲区,556,东南,5,2,0,36,55600,
珠海,香洲区,316,东南,4,2,4,42,40000,
珠海,香洲区,255,南北,4,2,3,17,30000,
珠海,香洲区,379.24,东南,6,2,3,24,29000,
珠海,香洲区,395,西,5,3,4,3,26000,
珠海,香洲区,299.43,东南,5,2,4,23,22000,
珠海,香洲区,211,东南,4,2,3,44,20000,
珠海,香洲区,260,东,1,0,0,33,20000,
珠海,香洲区,252,东,5,1,4,41,20000,
```

图 2-5 数据展示

```
#!/bin/bash
infile=$1
outfile=$2
awk -F "," 'BEGIN{
srand();
        id=0:
        id=id+1:
        print id"\t"$1"\t"$2"\t"$3"\t"$4"\t"$5"\t"$6"\t"$7"\t"$8"\t"$9
   }' $infile> $outfile
```

图 2-6 pre rent.sh

```
hadoop@dblab-VirtualBox:/usr/local/bigdata/dataset$ bash ./pre_rent.sh rent.csv
rent.txt
hadoop@dblab-VirtualBox:/usr/local/bigdata/dataset$ head -10 rent.txt
                香洲区香洲区香洲区
1
        珠海
                         397
                                 南
                                          9
                                                           8
                                                                   4
                                                                           100000
2
        珠海
                         556
                                 东南
                                          5
                                                  2
                                                           Θ
                                                                   36
                                                                           55600
        珠海
                                  东南
3
                         316
                                          4
                                                  2
                                                           4
                                                                   42
                                                                           40000
        珠海
                香洲区
                                 南北
4
                                          4
                                                  2
                                                           3
                                                                   17
                                                                           30000
                         255
                 香洲区
        珠海
5
                         379.24
                                 东南
                                          6
                                                  2
                                                           3
                                                                   24
                                                                           29000
                珠海
                                 西
6
                         395
                                          5
                                                  3
                                                           4
                                                                   3
                                                                           26000
        珠海
                                 东南
7
                                                  2
                         299.43
                                          5
                                                           4
                                                                   23
                                                                           22000
        珠海
                                 东南
8
                         211
                                                  2
                                                           3
                                                                   44
                                                                           20000
        珠海
                                 东
                                                  Θ
                                                           Θ
                                                                   33
                                                                           20000
9
                         260
                                          1
10
        珠海
                         252
                                 东
                                          5
                                                           4
                                                                   41
                                                                           20000
```

图 2-7 执行 shell 脚本并查看处理后数据

2.3.2 上传至 HDFS

```
hadoop@dblab-VirtualBox:/usr/local/hadoop$ ./bin/hdfs dfs -mkdir -p /bigdata/dat
hadoop@dblab-VirtualBox:/usr/local/hadoop$ ./bin/hdfs dfs -put /usr/local/bigdat
a/dataset/rent.txt /bigdata/dataset
hadoop@dblab-VirtualBox:/usr/local/hadoop$ ./bin/hdfs dfs -cat /bigdata/dataset/
rent.txt | head -10
1 珠海 香洲
                                  南东东东
                 香洲区
                         397
                                                            8
                 香洲区
        珠海
2
                         556
                                           5
                                                   2
                                                            0
                                                                    36
                                                                             55600
        珠海
3
                 香洲区
                                           4
                                                   2
                                                            4
                                                                    42
                                                                             40000
                         316
                 香洲区区香洲区区
4
5
        珠海
                                  南北
                                           4
                                                   2
                                                            3
                                                                    17
                                                                             30000
                         255
        珠海
                                  东南
                         379.24
                                           6
                                                   2
                                                            3
                                                                    24
                                                                             29000
6
        珠海
                                  西
                                                            4
                         395
                                                   3
                                                                    3
                                                                             26000
                                           5
        珠海
                                  东南
7
                         299.43
                                           5
                                                   2
                                                            4
                                                                    23
                                                                             22000
                                  东
东
东
东
                 香洲区香洲区
8
        珠海
                         211
                                           4
                                                   2
                                                            3
                                                                    44
                                                                             20000
        珠海
9
                         260
                                           1
                                                   0
                                                            0
                                                                    33
                                                                             20000
        珠海
                 香洲区
10
                         252
                                           5
                                                   1
                                                                             20000
cat: Unable to write to output stream.
```

图 2-8 成功上传图示

3. 数据分析

3.1 使用 Spark SQL 进行统计分析 (至少 5 个)

3.1.1 统计租金前 10 的市辖区

```
scala> import org.apache.spark.sql.SparkSession
import org.apache.spark.sql.SparkSession
scala> val df = spark.read.format("csv").option("header", "true").option("inferSchema", "true").load("fi
le:///usr/local/bigdata/dataset/rent.csv").toDF("district","address","area","orientation","room","living
","bathroom","floor","rent","null")
df: org.apache.spark.sql.DataFrame = [district: string, address: string ... 8 more fields]
scala> df.createOrReplaceTempView("myrent")
```

图 3-7 导入数据至 Spark sql

scala> val top10 = spark.sql("SELECT address, AVG(rent) AS avg_rent FROM myrent GROUP BY address ORDER B
Y avg_rent DESC LIMIT 10")
top10: org.apache.spark.sql.DataFrame = [address: string, avg_rent: double]

scala> top10.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql/top_ 10_rent")

图 3-8 查询结果图示

3.1.2 统计市辖区出租房屋的最大面积和最小面积

scala> val rent_show = spark.sql("SELECT address,avg(area) AS avg_area,avg(rent) AS avg_rent FROM myrent
group by(address)")
rent_show: org.apache.spark.sql.DataFrame = [address: string, avg_area: double ... 1 more field]

scala> rent_show.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql/
rent_show")

```
scala> val area_show = spark.sql("SELECT address,MAX(area) AS max_area, MIN(area) AS min_area from myren
t group by(address)")
area_show: org.apache.spark.sql.DataFrame = [address: string, max_area: double ... 1 more field]
scala> area show.show()
    address|max_area|min_area|
    148.0
                784.0İ
                         33.0i
                 126.0
                         80.0
                          47.1
                 216.0
                300.0
                         10.0
                 220.0
                         74.01
                 120.0
                        110.0
30.0
                        144.0
                                 46.01
                        15.0
               1000.0
                          5.01
        610.0|
                         30.0|
                183.0
                        16.0
                329.431
                         21.0|
                750.0
                         14.9
                511.78
                          9.0
                203.0
                         30.0
        茶凤镇|
                200.0
                         36.0
       一西区

坡头区
                214.0
               150.0
                         38.0|
only showing top 20 rows
scala> area_show.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql/
area_show")
                                      图 3-9 统计结果图示
3.1.3 统计市辖区出租房屋的平均面积及平均租金
scala> val rent_show = spark.sql("SELECT address,avg(area) AS avg_area,avg(rent) AS avg_rent FROM myrent
group by(address)")
rent_show: org.apache.spark.sql.DataFrame = [address: string, avg_area: double ... 1 more field]
scala> rent show.show()
  address| avg_area| avg_rent|
    三角镇| 87.82181818181817|1651.818181818181818
```

scala> rent_show.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql/
rent_show")

图 3-10 统计结果图示

3.1.4 统计地级市租金在 1000 以上的房屋数量

scala> val count_rent = spark.sql("SELECT district,count(*) as count_district FROM myrent where rent>100
0 group by(district)")
count_rent: org.apache.spark.sql.DataFrame = [district: string, count_district: bigint]

scala> count_rent.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql
/count_rent")

图 3-11 统计结果图示

3.1.5 统计地级市一房一厅一卫的房屋最低租金

scala> val min_rent = spark.sql("SELECT address,min(rent) as min_rent FROM myrent where room>1 and livin
g>1 and bathroom>1 group by(address)")
min_rent: org.apache.spark.sql.DataFrame = [address: string, min_rent: int]

```
scala> min_rent.show()
     address|min_rent|
         一三遂廉古赤东佛二
特溪江镇坎升冈
镇县市镇区镇县
                     1300
                      900
                     2300
                     2800
                      900
                     1500
                     1500
1600
                     1000|
          惠城|
禅城|
                     900
                    1500
         #门华田湾凤区以下,以区区区区区镇 | |
                      500|
                     2300
                     5200
                     1000
                     1600
                    1500 l
                     1300
only showing top 20 rows
```

scala> min_rent.rdd.map(row => row.mkString(",")).saveAsTextFile("file:///usr/local//bigdata/spark_sql/m
in_rent")

图 3-12 统计结果图示

4. Flask 与 ECharts 数据大屏可视化

本节中利用数学建模的知识构建了一个伪动态数据读取模型,配合 Flask 框架与 ECharts 绘图,构建了一个大屏可视化 web 界面,具体界面入下图所示。



图 4-1 数据大屏展示整体

4.1 开发环境及伪动态算法介绍

4.1.1 利用 Flask 与 ECharts

本文在 window 环境下利用 python3.9 搭建动态 web 应用。具体环境信息入下所示。

序号	运行环境
1	Linux(Ubuntu16.04)
2	Win11
3	Hadoop 2.7.1
4	Python 3.9
5	Pymysql 1.0.3
6	Flask 2.3.2
7	Echarts

表 4-1 动态 web 可视化项目所用配置

4.1.2 伪动态算法建模

本文所构建算法从读取数据部分入手,使不同时间序列下读取数据行数不同,使可视化结果中数据呈现动态的变化,关键式入下所示。

$$y = \begin{cases} 100 + \log_2 2^t & 0 \le t \le 15\\ 211.8 * t - 80 & 16 \le t \le 60 \end{cases}$$
 (4-1)

其中y为本次读取的数据条数,t为程序所处的时间环境,由下式所决定。

$$t = \begin{cases} t+1 & 0 \le t \le 60\\ 15 & t > 60 \end{cases} \tag{4-2}$$

具体代码如下图所示。

图 4-2 快启动-缓增长代码

4.2 Flask+ ECharts 可视化

4.2.1 数据导入 mysql

本文在 window 环境下通过 Navicat 软件直接将数据导入到 mysql 中。具体如下图所示。

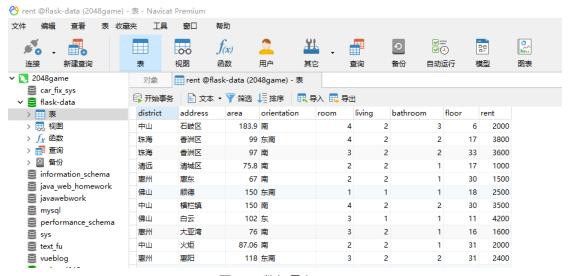


图 4-3 数据导入 mysql

4.2.2 总体情况预览可视化分析

在本节中将房源数量、房源均面积、房间数量、租房均价 4 个指标可视化的展示在图上。让读者更容易了解整体租房信息。

● Flask 代码

```
@app.route('/l1')

def get_l1_data():
    # 统计 area 的均值
    order = len(df)#汀单数里
    profit = int(df["area"].mean())#租房面积均值
    customer = int(df["room"].sum())#房间数里
    ATV =int(df["rent"].mean())#租房均价
    #print(ATV)

Peturn jsonify({"order": order, "profit": profit, "customer": customer, "ATV": ATV})
```

图 4-4 分析 1Flask 代码

● Web 代码

```
$.ajax({
    unl: "/\overline",
    success: function(data) {
        // data=JSON.parse(data)

        $("#order").html(data.order)
        $("#profit").html(data.profit)
        $("#customer").html(data.atv)
        },
        error: function(xhr, type, errorThrown) {
        }
    }
}
```

图 4-5 分析 1web 代码

● 可视化结果展示



图 4-6 分析 1 可视化展示

4.2.3 深圳、佛山租房各项指标对比

通过雷达图可以清楚的分析在相同的环境下,深圳与佛山两地二手房的价格 差别,本次选取租房中的房间数量、平均面积、均价、楼层层数、客厅数量五个 指标进行可视化。

● Flask 代码

```
Qapp.route('/l2')
Odef get_l2_data():
    # 过滤district为佛山和深圳的数据
    dfnew = df[df["district"].isin(['佛山', '梁圳'])]

# 分别计算两地的平均值
    mean_df = dfnew.groupby('district').mean().round(2)

# 转换为列表输出
    mean_list = mean_df[['area', 'room', 'living', 'floor', 'rent']].values.tolist()
    columns_list = ['area平均值', 'room平均值', 'living平均值', 'floor平均值', 'rent平均值']
    return jsonify({"new_customer": mean_list[8], "old_customer": mean_list[1]})
```

图 4-7 分析 2Flask 代码

● Web 代码

图 4-8 分析 2web 代码

● 可视化结果展示

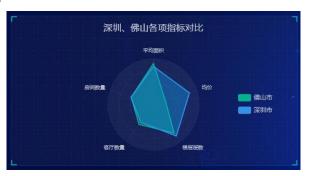


图 4-9 分析 2 可视化展示

4.2.4 不同朝向的租房房间数量、楼层可视化分析

通过对比不同朝向的租房房间数量、楼层等分析大致确定租房市场对于各个朝向的房源的容忍性。

● Flask 代码

```
@app.route('/l3')
[odef get_l3_data():#have done
# 分组并计算均值
result = df.groupby(['orientation'])[['room', 'floor']].mean().reset_index().round(0)
index = result["orientation"].tolist()
old_customer = result["room"].tolist()
new_customer = result["floor"].tolist()

Preturn jsonify({"index": index, "new_customer": new_customer, "old_customer": old_customer})
```

图 4-10 分析 3Flask 代码

● Web 代码

图 4-11 分析 3web 代码

● 可视化结果展示

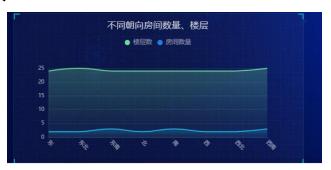


图 4-12 分析 3 可视化展示

4.2.5 地区均价与面积对比分析

通过比较不用地区的租房价格与面积的对比,可以直观的分析出不同地区的租房的价格差异、比较性价比。

● Flask 代码

```
result = df.groupby('address')[['rent', 'area']].mean().reset_index().round(2)
#print(type(result)) # 输出DataFrame的类型
index = result['address'].tolist()[:10] # 获取address列并转换为列表
sales = result['rent'].tolist()[:10] # 获取rent列并转换为列表
profit = result['area'].tolist()[:10] # 获取area列并转换为列表
return jsonify({"index": index, "sales": sales, "profit": [0 for _ in range(10)], "profit_rate": profit})
```

图 4-13 分析 4Flask 代码

● Web 代码

图 4-14 分析 4web 代码

● 可视化结果展示

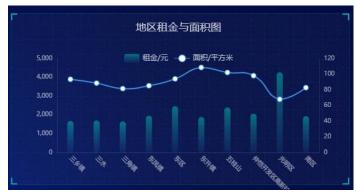


图 4-15 分析 4 可视化展示

4.2.6 房源数量 TOP10 分析

通过聚合排序各个不同地区的房源数量,并将结果展示到页面中,可以清楚的分析到哪些地区的房源饱和、哪些的稀缺。

● Flask 代码

```
@app.route('/r21')
idef get_r21_data():#have done
    top_10 = df.groupby('address').size().reset_index(name='count').sort_values('count', ascending=False).head(10)
#print(top_10)
#product_df = get_product().sort_values('sales', ascending=False).head(10)
return jsonify({"product": top_10['address'].tolist(), "sales": top_10['count'].tolist()[::-1]})
```

图 4-16 分析 5Flask 代码

● Web 代码

图 4-17 分析 5web 代码

● 可视化结果展示



图 4-18 分析 5 可视化展示

4.2.7 租房类型对比

针对不同价位的租房,本文将其分为3类,通过堆叠柱状图来分析与展示这3类房源的均面积、均价、数量的比较,结果清晰明了。

● Flask 代码

图 4-19 分析 6Flask 代码

● Web 代码

图 4-20 分析 6web 代码

● 可视化结果展示



图 4-21 分析 6 可视化展示

4.2.8 租房覆盖率分析展示

通过对比本次数据中出现的房源地区来分析该网站的房源覆盖的范围,通过

饼图将结果清晰展示出来。

● Flask 代码

图 4-22 分析 7Flask 代码

● Web 代码

图 4-23 分析 7web 代码

● 可视化结果展示



图 4-24 分析 7 可视化展示

4.3 总体大屏可视化结果展示

具体可视化结果如下图所示,请注意,本文使用的大屏展示是实时变化的,但图片无法展示效果。



图 4-25 最终大屏可视化展示

5. Spark 机器学习

5.1 K-Means 聚类分析

5.1.1 数据预处理

● 导入所需包

```
scala> import org.apache.spark.ml.feature.{StandardScaler, VectorAssembler, StringIndexer}
import org.apache.spark.ml.feature.{StandardScaler, VectorAssembler, StringIndexer}
scala> import org.apache.spark.sql.functions._
import org.apache.spark.sql.functions._
scala> import org.apache.spark.sql.{DataFrame, SparkSession}
import org.apache.spark.sql.{DataFrame, SparkSession}
scala> import org.apache.spark.ml.clustering.KMeans
import org.apache.spark.ml.clustering.KMeans
scala> import org.apache.spark.ml.feature.{VectorAssembler, StringIndexer, OneHotEncoder}
import org.apache.spark.ml.feature.{VectorAssembler, StringIndexer, OneHotEncoder}
scala> import org.apache.spark.sql.SparkSession
import org.apache.spark.sql.SparkSession
scala> import org.apache.spark.ml.Pipeline
import org.apache.spark.ml.Pipeline
scala> import org.apache.spark.ml.feature.{OneHotEncoder, StringIndexer, VectorAssembler}
import org.apache.spark.ml.feature.{OneHotEncoder, StringIndexer, VectorAssembler}
scala> import org.apache.spark.ml.linalg.Vector
import org.apache.spark.ml.linalg.Vector
scala> import spark.implicits._
import spark.implicits._
scala> import org.apache.spark.ml.tuning.ParamGridBuilder
import org.apache.spark.ml.tuning.ParamGridBuilder
scala> import org.apache.spark.ml.tuning.CrossValidator
import org.apache.spark.ml.tuning.CrossValidator
scala> import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator
import\ org. a pache. spark. \verb|ml.evaluation.MulticlassClassificationEvaluator| \\
```

图 5-1

● 读入数据

```
scala> val df = spark.read.format("csv").option("header", "true").option("inferSchema", "true").load("fi
le:///usr/local/bigdata/dataset/rent.csv").toDF("district","address","area","orientation","room","living
","bathroom","floor","rent","null")
df: org.apache.spark.sql.DataFrame = [district: string, address: string ... 8 more fields]
scala>
scala> val colsToDrop = Seq("null")
colsToDrop: Seq[String] = List(null)
scala> val data = df.drop(colsToDrop:_*)
data: org.apache.spark.sql.DataFrame = [district: string, address: string ... 7 more fields]
scala>
```

图 5-2

5.1.2 特征工程

● 字符串编码和独热编码

scala> // 字符串编码和独热编码

```
scala> val districtIndexer = new StringIndexer().setInputCol("district").setOutputCol("districtIndex")
districtIndexer: org.apache.spark.ml.feature.StringIndexer = strIdx_2f13681cd29a
```

scala> val districtEncoded = new OneHotEncoder().setInputCol("districtIndex").setOutputCol("districtVec"
)
districtEncoded: orq.apache.spark.ml.feature.OneHotEncoder = oneHot 5c3ec2361a4e

scala> val addressIndexer = new StringIndexer().setInputCol("address").setOutputCol("addressIndex")
addressIndexer: org.apache.spark.ml.feature.StringIndexer = strIdx_874c09baf9a0

scala> val addressEncoded = new OneHotEncoder().setInputCol("addressIndex").setOutputCol("addressVec")
addressEncoded: org.apache.spark.ml.feature.OneHotEncoder = oneHot_36df09831ce8

scala>

● 将特征向量合并为一个向量列

scala> // 将特征向量合并为一个向量列

scala> val assembler = new VectorAssembler().setInputCols(Array("districtVec", "addressVec", "area", "ro
om", "living", "bathroom", "floor")).setOutputCol("features")
assembler: org.apache.spark.ml.feature.VectorAssembler = vecAssembler_b641ceeaeebc
scala>

图 5-3

● 将 Pipeline 组合到一个流程中

scala> // 将Pipeline组合到一个流程中

scala> val pipeline = new Pipeline().setStages(Array(districtIndexer, addressIndexer, districtEncoded, a
ddressEncoded, assembler))
pipeline: org.apache.spark.ml.Pipeline = pipeline_6a49e11bfd57
scala>

图 5-4

5.1.3 K-Means 模型聚类

● 使用流程,处理数据并拟合 K-Means 模型

```
scala> val preprioressedDF = pipelineModel = pipeline_6a49e11bfd57

scala> val preprocessedDF = pipelineModel.transform(data)
preprocessedDF: org.apache.spark.ml.PipelineModel.transform(data)
preprocessedDF: org.apache.spark.sql.DataFrame = [district: string, address: string ... 12 more fields]

scala> val kmeans = new KMeans().setK(3).setFeaturesCol("features").setPredictionCol("prediction")
kmeans: org.apache.spark.ml.clustering.KMeans = kmeans_a2e5d2c950cc

scala> val model = kmeans.fit(preprocessedDF)
23/05/20 00:11:28 MARN KMeans: The input data is not directly cached, which may hurt performance if its parent RDDs are also uncached.
23/05/20 00:11:30 MARN BLAS: Falled to load implementation from: con.github.fommil.netlib.NativeSystemBLAS
23/05/20 00:11:33 WARN BLAS: Falled to load implementation from: com.github.fommil.netlib.NativeRefBLAS
23/05/20 00:11:33 WARN KMeans: The input data was not directly cached, which may hurt performance if its parent RDDs are also uncached.
org.apache.spark.ml.clustering.KMeansModel = kmeans_a2e5d2c950cc
```

图 5-5 模型图示

● 使用 K-Means 模型进行预测,并展示结果

图 5-6

● 模型的所有聚类中心情况

scalar model.clusterCenters.foreach(center => (println("Clustering Center":*center)) (clustering Center":*center)) (clustering Center":*center)) (clustering Center":*center) (clustering Center") (clustering Ce

图 5-7

● 输出每个簇的大小

图 5-8

● 输出每个簇的数据统计信息

scala>

scala> //输出每个簇的数据统计信息

scala> predictions.groupBy("prediction").count.orderBy("prediction").show()
+------+
|prediction|count|

图 5-9

5.1.4 模型评估

● WSSSE (集合内误差平方和) 度量聚类的有效性

scala> model.computeCost(preprocessedDF)
res4: Double = 1.0264313547817148E7
scala>

图 5-10

该模型的 WSSSE 值为: 1.0264, 该值越小可说明模型的有效性越高;

5.1.5 模型优化

scala> bk_model.computeCost(preprocessedDF)
res6: Double = 1.2667938287165424E7

图 5-11

使用二分 k-Means 模型得到聚类 WSSSE 分数为 1.266>1.102, 可得上述 K-Means 模型已为当前区间最优解。

5.1.6 结论

根据模型聚类所得结果,该数据集可分为三类:类型 0-面价最大,房间数最多,租金最高,多数位于中山、湛江等地区,适宜租来做为厂房/工作室等多人工作的场地;类型 1-面积最小,房间数最少,租金最少,但仍处于两千以上,推测是处于出行便利或市中心,多数处于深圳等发达城市,适宜独居的上班人员;类型 2-面积适中,租金适中,适合合租、一家人租住;

5.2 Lasso 回归模型预测租金

5.2.1 数据预处理

● 导包

```
scala> import org.apache.spark.ml.regression.LinearRegression
import org.apache.spark.ml.regression.LinearRegression
scala> import org.apache.spark.ml.regression.LinearRegressionModel
import org.apache.spark.ml.regression.LinearRegressionModel
scala> import org.apache.spark.ml.feature.VectorAssembler
import org.apache.spark.ml.feature.VectorAssembler
scala> import org.apache.spark.sql.SparkSession
import org.apache.spark.sql.SparkSession
scala> import org.apache.spark.ml.evaluation.RegressionEvaluator
import org.apache.spark.ml.evaluation.RegressionEvaluator
scala> import org.apache.spark.ml.regression.{LinearRegression, LinearRegressionModel}
import org.apache.spark.ml.regression.{LinearRegression, LinearRegressionModel}
scala> import org.apache.spark.ml.tuning.{CrossValidator, ParamGridBuilder}
import org.apache.spark.ml.tuning.{CrossValidator, ParamGridBuilder}
scala> import org.apache.spark.ml.feature.VectorAssembler
import org.apache.spark.ml.feature.VectorAssembler
```

图 5-12

● 字符串编码和独热编码

scala> // 字符串编码和独热编码

scala> val districtIndexer = new StringIndexer().setInputCol("district").setOutputCol("districtIndex") districtIndexer: org.apache.spark.ml.feature.StringIndexer = strIdx_2f13681cd29a

scala> val districtEncoded = new OneHotEncoder().setInputCol("districtIndex").setOutputCol("districtVec" districtEncoded: org.apache.spark.ml.feature.OneHotEncoder = oneHot_5c3ec2361a4e

scala> val addressIndexer = new StringIndexer().setInputCol("address").setOutputCol("addressIndex") addressIndexer: org.apache.spark.ml.feature.StringIndexer = strIdx_874c09baf9a0

scala> val addressEncoded = new OneHotEncoder().setInputCol("addressIndex").setOutputCol("addressVec") addressEncoded: org.apache.spark.ml.feature.OneHotEncoder = oneHot_36df09831ce8

scala>

scala>

图 5-13

5.2.2 特征工程

将特征向量合并为一个向量列

scala> // 将特征向量合并为一个向量列

scala> val assembler = new VectorAssembler().setInputCols(Array("districtVec", "addressVec", "area", "ro
om", "living", "bathroom", "floor")).setOutputCol("features")
assembler: org.apache.spark.ml.feature.VectorAssembler = vecAssembler_b641ceeaeebc

图 5-14

将 Pipeline 组合到一个流程中

scala> // 将Pipeline组合到一个流程中

scala> val pipeline = new Pipeline().setStages(Array(districtIndexer, addressIndexer, districtEncoded, a ddressEncoded, assembler))
pipeline: org.apache.spark.ml.Pipeline = pipeline_6a49e11bfd57 scala>

图 5-15

5.2.3 构建模型

定义、拟合 Lasso 回归模型

scala> // 定义、拟合Lasso回归模型

scala> val lasso = new LinearRegression().setElasticNetParam(1).setRegParam(0.01).setLabelCol("rent")
lasso: org.apache.spark.ml.regression.LinearRegression = linReg_893c20a50509

scala> val lassoModel = lasso.fit(preprocessedDF) lassoModel: org.apache.spark.ml.regression.LinearRegressionModel = linReg_893c20a50509

scala>

图 5-16

5.2.4 模型评估

● Lasso 回归模型系数

scala> // 打印Lasso回归模型系数

scalap printin(s'Lasso Coefficients: \$(lassomodel.coefficients)")
Lasso Coefficients: [-7.89.3918977357117, 1265.462510333086, -487.7304082114919, -699.0043161984365, 159.04826460375787, -259.3870882475447, -613.72120813877834, -7.
07.38.771627558059, -7.18.771620809011, -559.59.2716523244716, -446.0717925256166, -438.04654651454265, 712.1.1388311925055, 1475.211288559279, 1588.1081591173996, -882.
07.38.77162755805, -7.18.781620809011, -559.59.2716523244716, -446.04554651454265, 712.1.1388311925055, 1475.211286559279, 1588.1081591173996, -882.
07.28.771627577, -1486.045790644435, -478.107145448959, 3538, 18004077643, -7124. 19050541766, -446. 1300205937766, -88.73914792477809, -271.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.008183723077, -717.00818372307, -717.008183

图 5-17

查看预测结果

trict addr	ress area orientatio	on room livin	g bathroom	floor r	ent districtInd	dex addressIndex	districtVec	addressVec	features	prediction
珠海	香洲区 556.0	东南	5 2	0	36 55600	4.0	2.0[(6,[4],	[1.0]) (59,[2],[1.	0]) (70,[4,8,65,66,67.	24519.15650496
珠海	香洲区 316.0	东南i	4 2	4	42 40000	4.0	2.0 (6, [4],	[1.0]) (59,[2],[1.	0]) (70,[4,8,65,66,67.	15456.42472074
珠海海 	香洲区 255.0	东南东西,南南 市南南,东东东东东东东东东东东东东东东东东东东东东东东东东东东东东东东东	4 2	3	17 30000	4.0	2.0 [6, [4],	[1.0]) (59,[2],[1.	0]) (70,[4,8,65,66,67.	11377.2769659
珠海	香洲区[379.24]	东南i	6 2	3	24 29000	4.0			0]) (70,[4,8,65,66,67.	
珠海	香洲区[395.0]	西广ち	31	41	3 26000	4.0	2.0[(6,[4],[1.0]) (59,[2],[1.0]) (70,[4,8,65,66,67	17089.647316574
珠海	香洲区[299.43]	东南」	51 21	41	23 22000	4.01			0]) (70,[4,8,65,66,67.	
珠海	香洲区 211.0	东南i	4 2	3	44 20000	4.0			0]) (70,[4,8,65,66,67.	
珠海	香洲区 260.0	东 1 东 5 南 1	0 0	61	331200001	4.0]) (70,[4,8,65,66,69	
珠海	香洲区 252.0	东i 5	i 1i	41	41 20000	4.0			1) (70, [4, 8, 65, 66, 67	
珠海	香洲区 197.55	南 1	0	6	19 18500	4.0]) (70,[4,8,65,66,69	

only showing top 10 rows

图 5-18

● 均方根误差(RMSE)评估

```
scala> // 均方根误差(RMSE)评估
scala> val lassoEvaluator = new RegressionEvaluator().setLabelCol("rent").setPredictionCol("prediction").setMetricName("rmse")
lassoEvaluator: org.apache.spark.ml.evaluation.RegressionEvaluator = regEval_e83aff8d056d
scala> val lassoPredictions = lassoModel.transform(preprocessedDF)
lassoPredictions: org.apache.spark.sql.DataFrame = [district: string, address: string ... 13 more fields]
scala> val lassoRmse = lassoEvaluator.evaluate(lassoPredictions)
lassoRmse: Double = 2712.8004081058803
```

图 5-19

5.2.5 参数调优

● 设置 Lasso 参数网格并定义评估器

图 5-20

● 使用交叉验证调优 Lasso 回归模型

```
|scala> val lassoCV = new CrossValidator().setEstimator(lasso).setEvaluator(evaluator).setEstimatorParamM
lassoParamGrid).setNumFolds(5)
lassoCV: org.apache.spark.ml.tuning.CrossValidator = cv_c7af18dd70ab
scala>
scala> val lassoCVModel = lassoCV.fit(preprocessedDF)
23/05/20 00:12:15 WARN Executor: 1 block locks were not released by TID = 752:
[rdd_347_0]
23/05/20 00:12:16 WARN Executor: 1 block locks were not released by TID = 758:
23/05/20 00:12:16 WARN Executor: 1 block locks were not released by TID = 764:
[rdd 347 0]
23/05/20 00:12:16 WARN Executor: 1 block locks were not released by TID = 770:
[rdd_347_0]
23/05/20 00:12:18 WARN Executor: 1 block locks were not released by TID = 780:
\frac{1}{23}/05/2000:12:18 WARN Executor: 1 block locks were not released by TID = 786:
[rdd 461 0]
23/05/20 00:12:18 WARN Executor: 1 block locks were not released by TID = 792:
[rdd_461_0]
|23/05/20_00:12:19_WARN_Executor: 1_block_locks_were_not_released_by_TID = 798:
[rdd_461_0]
23/05/20 00:12:19 WARN Executor: 1 block locks were not released by TID = 808:
[rdd 575 0]
23/05/20 00:12:20 WARN Executor: 1 block locks were not released by TID = 814:
[rdd_575_0]
23/05/20 00:12:20 WARN Executor: 1 block locks were not released by TID = 820:
[rdd_575_0]
23/05/20 00:12:20 WARN Executor: 1 block locks were not released by TID = 826:
[rdd_575_0]
23/05/20 00:12:21 WARN Executor: 1 block locks were not released by TID = 836:
[rdd 689 0]
23/05/20 00:12:21 WARN Executor: 1 block locks were not released by TID = 842:
[rdd_689_0]
23/05/20 00:12:22 WARN Executor: 1 block locks were not released by TID = 848:
[rdd_689_0]
23/05/20 00:12:22 WARN Executor: 1 block locks were not released by TID = 854:
[rdd 689 0]
23/05/20 00:12:23 WARN Executor: 1 block locks were not released by TID = 864:
[rdd_803_0]
23/05/20 00:12:23 WARN Executor: 1 block locks were not released by TID = 870:
[rdd_803_0]
23/95/20 00:12:23 WARN Executor: 1 block locks were not released by TID = 876:
[rdd_803_0]
\frac{1}{23}/05/2000:12:23 WARN Executor: 1 block locks were not released by TID = 882:
lassoCVModel: org.apache.spark.ml.tuning.CrossValidatorModel = cv_c7af18dd70ab
```

图 5-21

● 打印最优参数

```
scala> // 打印Lasso交叉验证模型最优参数和MAE
scala> println(s"Lasso CV Model - Best Parameter: ${lassoCVModel.bestModel.asInstanceOf[LinearRegression Model].getRegParam}")
Lasso CV Model - Best Parameter: 10.0
scala> val lassoPredictions = lassoCVModel.transform(preprocessedDF)
lassoPredictions: org.apache.spark.sql.DataFrame = [district: string, address: string ... 13 more fields
]
scala> val lassoMAE = evaluator.evaluate(lassoPredictions)
lassoMAE: Double = 1074.4850092626211
scala> println(s"Lasso CV Model - MAE: $lassoMAE")
Lasso CV Model - MAE: 1074.4850092626211
```

图 5-22

结果可得最优 Parameter 参数为 10, RMSE 值也从 2710 降至 1074, 证明模型调优有效。

6. 实时分析

6.1 出租房屋数量实时分析

6.1.1 实验环境准备

● python 工程目录结构

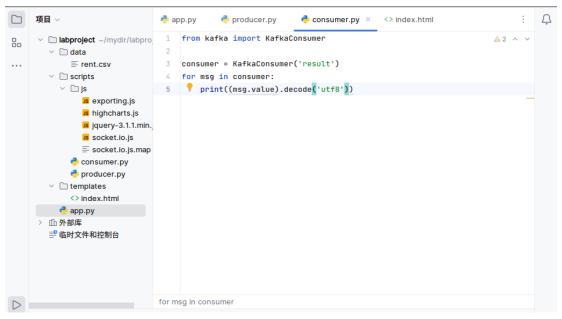


图 6-1

6.1.2 数据处理和 Python 操作 Kafka

● 启动 kafka 服务

```
hadoop@dblab-VirtualBox:~$ cd /usr/local/kafka
hadoop@dblab-VirtualBox:/usr/local/kafka$ bin/kafka-server-start.sh config/serve
r.properties
[2023-05-30 14:05:00,177] INFO KafkaConfig values:
        advertised.host.name = null
        advertised.listeners = null
        advertised.port = null
        authorizer.class.name =
        auto.create.topics.enable = true
        auto.leader.rebalance.enable = true
        background.threads = 10
        broker.id = 0
       broker.id.generation.enable = true
hadoop@dblab-VirtualBox:~$ cd /usr/local/kafka
hadoop@dblab-VirtualBox:/usr/local/kafka$ ./bin/zookeeper-server-start.sh config
/zookeeper.properties
[2023-05-30 14:04:48,210] INFO Reading configuration from: config/zookeeper.prop
erties (org.apache.zookeeper.server.quorum.QuorumPeerConfig)
[2023-05-30 14:04:48,217] INFO autopurge.snapRetainCount set to 3 (org.apache.zo
okeeper.server.DatadirCleanupManager)
[2023-05-30 14:04:48,217] INFO autopurge.purgeInterval set to 0 (org.apache.zook
eeper.server.DatadirCleanupManager)
[2023-05-30 14:04:48,217] INFO Purge task is not scheduled. (org.apache.zookeepe
r.server.DatadirCleanupManager)
```

图 6-2

● 编写生产者文件

```
# coding: utf-8
                                                                   A1 ^ ~
    import csv
    import time
    from kafka import KafkaProducer
    # 实例化一个KafkaProducer示例,用于向Kafka投递消息
 6
    producer = KafkaProducer(bootstrap_servers='localhost:9092')
    # 打开数据文件
    csvfile = open("../data/rent.csv", "r")
 9
    # # 生成一个可用于读取csv 文件的reader
10
    reader = csv.reader(csvfile)
11
13
    for line in reader:
        rent = line[8] # 性别在每行日志代码的第9个元素
15
       if rent == 'rent':
           continue # 去除第一行表头
       time.sleep(0.1) # 每隔0.1秒发送一行数据
17
18
        # 发送数据, topic为'sex'
        producer.send('rent', line[8].encode('utf8'))
```

图 6-3

● 编写消费者文件

```
from kafka import KafkaConsumer

consumer = KafkaConsumer('result')
for msg in consumer:
print((msg.value).decode('utf8'))
```

图 6-4

6.1.3 Spark Streaming 实时处理数据

● 编写日志文件

图 6-5

● 编写工程主文件

```
KafakaTest.scala
object KafkaWordCount {
  implicit val formats = DefaultFormats//数据格式化时需要
  def main(args: Array[String]): Unit={
    if (args.length < 4) {
   System.err.println("Usage: KafkaWordCount <zkQuorum> <group> <topics> <numThreads>")
      System.exit(1)
    StreamingExamples.setStreamingLogLevels()
    /* 输入的四个参数分别代表着
    * 1. zkQuorum 为zookeeper地址
    * 2. group为消费者所在的组
    * 3. topics该消费者所消费的topics
    * 4. numThreads开启消费topic线程的个数
    val Array(zkQuorum, group, topics, numThreads) = args
val sparkConf = new SparkConf().setAppName("KafkaWord()
val ssc = new StreamingContext(sparkConf, Seconds(1))
    ssc.checkpoint(".") //这里表示把检查点文件写入分布式文件系统HDFS,所以要启动Hadoop
        //ssc.checkpoint("file:///usr/local/spark/mycode/kafka/checkpoint")
    // 将topics转换成topic-->numThreads的哈稀表
    val topicMap = topics.split(",").map((_, numThreads.toInt)).toMap
    // 创建连接Kafka的消费者链接
    val lines = KafkaUtils.createStream(ssc, zkQuorum, group, topicMap).map(_._2)
    val words = lines.flatMap(_.split(" "))//将输入的每行用空格分割成一个个word
    // 对每一秒的输入数据进行reduce,然后将reduce后的数据发送给Kafka
    val wordCounts = words.map(x => (x, 1L))
      reduceByKeyAndWindow(_+_,_-, Seconds(1), Seconds(1), 1).foreachRDD(rdd => {
   if(rdd.count !=0) }{
               props.put(ProducerConfig.VALUE_SERIALIZER_CLASS_CONFIG,
props.put(ProducerConfig.VALUE_SERIALIZER_CLASS_CONFIG,
               props.put(ProducerConfig.KEY_SERIALIZER_CLASS_CONFIG,
               // 实例化一个Kafka生产者
               val producer = new KafkaProducer[String, String](props)
               // rdd.colect即将rdd中数据转化为数组,然后write函数将rdd内容转化为json格式
               val str = write(rdd.collect)
               // 封装成Kafka消息,topic为"result"
               val message = new ProducerRecord[String, String]("result", null, str)
               // 给Kafka发送消息
               producer.send(message)
      })
    ssc.start()
    ssc.awaitTermination()
 }
                                                 图 6-6
  编写 simple.sbt
```

```
name := "Simple Project"
version := "1.0"
scalaVersion := "2.11.8"
libraryDependencies += "org.apache.spark" %% "spark-core" % "2.1.0" libraryDependencies += "org.apache.spark" % "spark-streaming_2.11" % "2.1.0" libraryDependencies += "org.apache.spark" % "spark-streaming-kafka-0-8_2.11" % "2.1.0" libraryDependencies += "org.json4s" %% "json4s-jackson" % "3.2.11"
```

图 6-7

打包上述程序

```
hadoop@dblab-VirtualBox:/usr/local/spark/mycode/kafka$ /usr/local/sbt/sbt packag
OpenJDK 64-Bit Server VM warning: ignoring option MaxPermSize=256M; support was
removed in 8.0
[info] Set current project to Simple Project (in build file:/usr/local/spark/myc
ode/kafka/)
[info] Updating {file:/usr/local/spark/mycode/kafka/}kafka...
[info] Resolving org.glassfish.jersey.containers#jersey-container-servlet;2.22.2
[info] Resolving org.glassfish.jersey.containers#jersey-container-servlet-core;2
[info] Resolving com.fasterxml.jackson.module#jackson-module-scala_2.11;2.6.5 ...
[info] Resolving jline#jline;2.12.1 ...
[info] Done updating.
[info] Compiling 2 Scala sources to /usr/local/spark/mycode/kafka/target/scala-2
.11/classes..
[info] Packaging /usr/local/spark/mycode/kafka/target/scala-2.11/simple-project_
2.11-1.0.jar ...
[info] Done packaging.
[success] Total time: 30 s. completed 2023-5-30 14:19:58
```

图 6-8

● 编写运行脚本

```
Musr/local/spark/bin/spark-submit --driver-class-path /usr/local/spark/jars/*:/usr/local/spark/jars/kafka/* --class "org.apache.spark.examples.streaming.KafkaWordCount" /usr/local/spark/mycode/kafka/target/scala-2.11/simple-project_2.11-1.0.jar 127.0.0.1:2181 1 rent 1
```

图 6-9

运行脚本

图 6-10

6.1.4 分析系统

● 同时运行 Spark Streaming 项目、producer、consumer 之后,可在 consumer

运行窗口得到如下结果

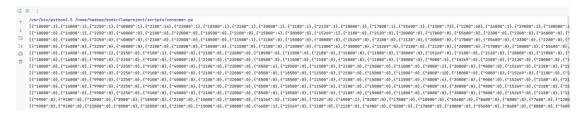


图 6-11

● 结果显示

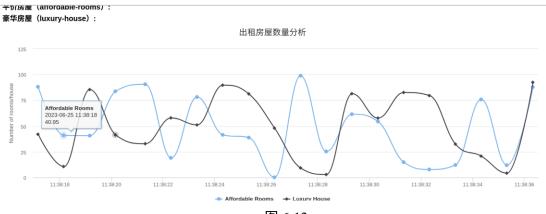


图 6-12

7. 总结

本项目通过 EXCEL 对出租房屋数据集进行预处理,并使用 Spark SQL 进行了租金前十的市辖区、各市辖区出租房屋的最大面积、最小面积、平均面积等数据分析;使用 Flask+Echarts 对数据进行大屏可视化;使用 K-Means 聚类对出租房屋进行聚类分析,根据聚类结果可知,该数据集可分为三类;使用 Lasson 回归模型进行预测租金,该模型优化后 RMSE 值为 1074;

在实现这个项目的过程中,我认为最重要的是对数据的预处理,通过对数据进行清洗和去重,可以保证得到准确的分析结果。其次,对不同的分析方法和模型进行尝试和比较,可以得到更好的结果,并且可以充分发掘数据的潜力。最后,大屏可视化和交互式图表的使用可以让数据的展示更加生动和直观,便于用户理解和使用。

总体来说,这是一个非常实用和有用的项目,可以为房屋租赁市场的参与者 提供很好的参考和指导。